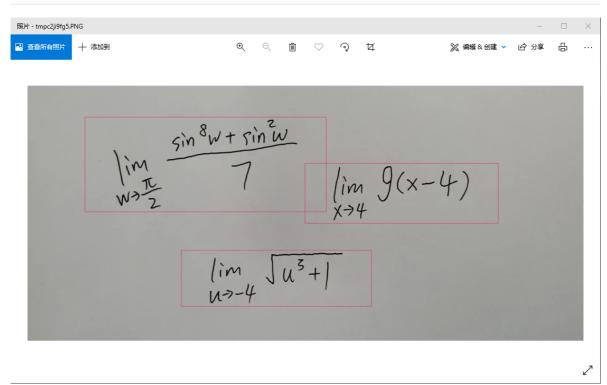
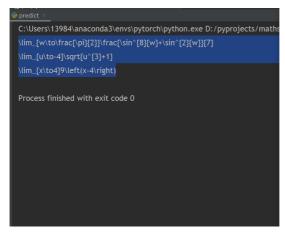
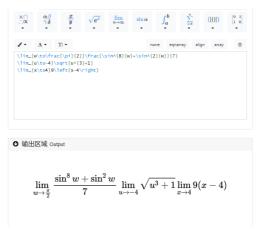
代码文档与数据集说明

demo







数据集

由于数据集有11GB不便于邮件传输,因此给出Aida数据集在kaggle上的官方网址:

https://www.kaggle.com/datasets/aidapearson/ocr-data

kaggle下载链接:

https://www.kaggle.com/datasets/aidapearson/ocr-data/download

支持的数学符号有(便于测试手写图片时查看):

- 0-9
- a-z
- A-Z
- lim极限符号

- 小括号与大括号
- αβγθ
- . .
- 🗸 .
- \bullet + $\times \div \pm$
- 1
- < = > ≤ ≥ ≠ ≈
- log ln
- 所有三角函数与反三角函数

如果要下载数据集并进行模型的训练,需要在datasets/preprocess.py中指定数据集路径,并运行这个脚本进行预处理。

checkpoint下载

下载链接为:

链接: https://pan.baidu.com/s/1lqdy qGqN8xwAlk WN7 aQ

提取码: dohw

--来自百度网盘超级会员V1的分享

在下载完成后:

- 将pretrain.pth移动到checkpoints/下
- 将model-30-beam.pth移动到data-beam/下
- 将model-30-greedy.pth移动到data-greedy/下

使用说明

代码运行环境最好保证如下三点:

- 1. python >= 3.7
- 2. torch >= 1.9.1
- 3. torchvision \geq 0.10.1
- 4. linux、windows系统下的Anaconda平台经测试均可使用

运行方式:

```
pip install -r requirements.txt
python3 predict.py
```

在predict.py中有如下一行可以指定测试图片路径:

```
change your path to the test pic here
your_path_to_pic = './pics/test1.jpg'
```

如果要测试自己的图片,尽量保证以下几点来确保模型预测准确性:

- 1. 白纸黑字
- 2. 背景尽量没有其他颜色的干扰
- 3. 不同公式之间尽量保证一定间隔
- 4. 公式符号应在上述支持的字典中,lim开头的公式预测效果较优

在生成序列后建议进入https://www.latexlive.com/复制模型输出来观察LaTeX公式效果。

代码说明

pics/: 提供了两张测试图片,一张为自己手写并包括多个公式,一张为数据集中的样例。

data-beam/: 使用集束搜索的模型权重与训练、测试log

data-greedy/: 使用贪婪算法的模型权重与训练、测试log, 我们使用这一份权重。

configs/: 提供了模型的配置以及token map字典,可以通过token map在没有数据集的情况下进行图

片的预测。

datasets/: 提供了数据集的预处理功能以及数据集的加载功能。

model/: encoder、decoder与完整模型的pytorch实现,这一部分参考了ASTER论文的代码并在其基

础上进行修改,详见论文。

utils/: 提供了log、checkpoint与图片、序列处理的功能。

predict.py: 一般图片的预测脚本

test.py: 测试脚本

train.py: 训练脚本